

Оптимизация ансамблей градиентного бустинга через адаптивное обучение агрегирующих функций

Якушевич Антон Сергеевич

ВМК МГУ

Научный руководитель: д.ф.-м.н. Сенько Олег Валентинович

2025

- Градиентный бустинг — мощный метод в машинном обучении
- Проблема: выбор агрегирующей функции
- Цель: снизить количество деревьев в ансамбле, сохранив при этом качество модели

Постановка задачи

Пусть задана последовательность функций $\{F_N\}_{N=1}^{+\infty}$, где $F_N : \mathbb{R}^N \rightarrow \mathbb{R}$. На $(N + 1)$ -ом шаге обучения вместо стандартной суммы $\sum_{i=1}^N T_i(x)$ будем использовать обобщённую функцию ансамбля $F_N(T_1(x), T_2(x), \dots, T_N(x))$, где $\{T_i\}_{i=1}^N$ – базовые модели (решающие деревья), обученные на предыдущих шагах.

Дано:

Выборка $X^\ell = \{(x_i, y_i)\}_{i=1}^\ell$, где $y_i \in \mathbb{R}$.

Найти:

Последовательность агрегирующих функций F_N .

Критерий:

Улучшение качества при фиксированном N относительно функции потерь $\mathcal{L}$ ($RMSE$, MAE и R^2), по сравнению с классическим градиентным бустингом, использующим сумму в качестве агрегирующей функции.

Параметризация агрегирующей функции

Разложение в ряд Тейлора функции $F_N(T_1(x), T_2(x), \dots, T_N(x))$ будет выглядеть следующим образом:

$$\sum_{k=0}^{+\infty} \left[\overbrace{\sum_{k_1=0} \sum_{k_2=0} \dots \sum_{k_N=0}}^{k_1+k_2+\dots+k_N=k} \frac{1}{k_1!k_2! \dots k_N!} \frac{\partial^k F_N(a_1, a_2, \dots, a_N)}{\partial T_1^{k_1} \partial T_2^{k_2} \dots \partial T_N^{k_N}} \prod_{i=1}^N (T_i(x) - a_i)^{k_i} \right]$$

В качестве агрегирующей функции будем использовать усечённый ряд Тейлора:

$$F_N(x) = \sum_{k=1}^M \overbrace{\sum_{k_1=0} \sum_{k_2=0} \dots \sum_{k_N=0}}^{k_1+k_2+\dots+k_N=k} b_{k_1, k_2, \dots, k_N} T_1^{k_1}(x) T_2^{k_2}(x) \dots T_N^{k_N}(x)$$

Стратегия обучения нового алгоритма

1. Нахождение точного корня:

$$F_{N+1}(x_i) = y_i \quad \Rightarrow \quad \sum_{k=0}^M C_k(x_i) \cdot (T_{N+1}(x_i))^k = y_i$$

2. Градиент:

$$T_{N+1}(x_i) = -\alpha \cdot C_1(x_i) \cdot \left. \frac{\partial \mathcal{L}(y_i, F)}{\partial F} \right|_{F=F_N(x_i)}$$

- Learning rate: $\alpha = \frac{\delta}{N^\theta}$
- $C_k(x)$ — функции, однозначно задаваемые $T_1(x), \dots, T_N(x)$

Оптимизация коэффициентов b

Для фиксированного датасета $\mathcal{D}$ вводится оператор $A_{\mathcal{D}}(b) : \mathbb{R}^P \rightarrow \mathbb{R}$, который запускает кросс-валидацию: на каждом фолде обучает наш бустинг с заданными коэффициентами b и возвращает среднюю ошибку по всем фолдам.


Частные производные:

$$\left. \frac{\partial A_{\mathcal{D}}}{\partial b_i} \right|_{b=b_0} \approx \frac{A_{\mathcal{D}}(b_0 + \varepsilon \cdot e_i) - A_{\mathcal{D}}(b_0)}{\varepsilon}$$

Градиентный спуск с моментом:

$$\begin{cases} v^{(k+1)} = \mu v^{(k)} - \eta \nabla_b A_{\mathcal{D}}(b^{(k)}) \\ b^{(k+1)} = b^{(k)} + v^{(k+1)} \end{cases}$$

Мета-модель



Оптимизационная задача:

$$\min_{\phi} \left[\log \left(1 + A_{\mathcal{D}}(\Psi_{\phi}(\mathcal{D})) \right) + \|\Psi_{\phi}(\mathcal{D})\|_2 \right]$$

где Ψ_{ϕ} — нейронная сеть с параметрами ϕ , формирующая вектор коэффициентов $b = \Psi_{\phi}(\mathcal{D})$, используемых при построении ансамбля

- **GB**: Стандартный градиентный бустинг (сумма деревьев).
- **FGBReg** (Functional Gradient Boosting Regressor): Базовый вариант предлагаемой модели с следующей формулой агрегирующей функции:

$$F_N(x) = \sum_{k=1}^M \sum_{k_1+\dots+k_N=k} \frac{1}{k} \cdot T_1^{k_1}(x) \cdot T_2^{k_2}(x) \cdots T_N^{k_N}(x)$$

- **FGBReg + GD**: Оптимизация коэффициентов градиентным спуском.
- **FGBReg + NN**: Оптимизация с помощью нейронной мета-модели.

Набор данных	GB	FGBReg	FGBReg + GD	FGBReg + NN
task1	93.69	95.72	86.78	99.43
task6	123.8	119.7	107.4	132.8
task7	8.424	8.380	8.366	8.378
task10	0.177	0.178	0.233	0.161
task16	41.03	33.54	32.05	35.99
task18	68.85	77.60	74.45	81.50
task41	0.401	0.364	0.356	0.345
task901	309.0	361.7	367.1	655.7
task970	40688	46121	45923	51427

Таблица: *RMSE*

Набор данных	GB	FGBReg	FGBReg + GD	FGBReg + NN
task1	67.09	72.21	62.40	79.40
task6	78.33	89.09	76.50	107.2
task7	6.857	6.788	6.786	6.816
task10	0.165	0.166	0.222	0.151
task16	32.83	25.95	24.84	28.70
task18	51.55	57.69	53.00	64.39
task41	0.211	0.194	0.197	0.202
task901	189.1	244.5	249.6	424.6
task970	28994	32799	32810	34680

Таблица: MAE

Набор данных	GB	FGBReg	FGBReg + GD	FGBReg + NN
task1	0.704	0.711	0.755	0.695
task6	0.654	0.723	0.762	0.661
task7	0.319	0.335	0.336	0.340
task10	-0.863	0.207	-0.108	0.303
task16	-11.28	-10.42	-11.61	-13.33
task18	0.681	0.642	0.603	0.617
task41	-0.503	-0.199	-0.133	-0.057
task901	0.919	0.894	0.891	0.716
task970	0.728	0.695	0.694	0.634

Таблица: R^2

- Заменяли сумму на гибкую агрегирующую функцию.
- Научились оптимизировать её коэффициенты.
- При тех же 20 деревьях оптимизация (особенно GD) заметно снижает $RMSE/MAE$ и повышает R^2
- Мета-сеть быстро генерирует хорошие коэффициенты для новых задач

Список литературы I



Leo Breiman.

Bagging predictors.

Machine Learning, 24(2):123–140, 1996.



Yoav Freund and Robert E. Schapire.

A decision-theoretic generalization of on-line learning and an application to boosting.

Journal of Computer and System Sciences, 55(1):119–139, 1997.



Jerome H. Friedman.

Greedy function approximation: A gradient boosting machine.

The Annals of Statistics, 29(5):1189–1232, 2001.



Tianqi Chen and Carlos Guestrin.

Xgboost: A scalable tree boosting system.

In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.



Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, and Tie-Yan Liu.

Lightgbm: A highly efficient gradient boosting decision tree.

In *Advances in Neural Information Processing Systems 30*, 2017.



Tong Zhang and Bin Yu.

Boosting with early stopping: Convergence and consistency.

The Annals of Statistics, 33(4):1538–1579, 2005.



Peter Bühlmann and Torsten Hothorn.

Boosting algorithms: Regularization, prediction and model fitting.

Statistical Science, 22(4):477–505, 2007.

Список литературы II



Llew Mason, Jonathan Baxter, Peter Bartlett, and Marcus Frean.

Boosting algorithms as gradient descent.

In *Advances in Neural Information Processing Systems 12*, 2000.



Jerome H. Friedman.

Stochastic gradient boosting.

Computational Statistics & Data Analysis, 38(4):367–378, 2002.



Dragos D. Margineantu and Thomas G. Dietterich.

Pruning adaptive boosting.

In *Proceedings of the 14th International Conference on Machine Learning*, pages 211–218, 1997.



Rich Caruana, Alexandru Niculescu-Mizil, Geoff Crew, and Alex Ksikes.

Ensemble selection from libraries of models.

In *Proceedings of the 21st International Conference on Machine Learning*, 2004.



Trevor Hastie, Robert Tibshirani, and Jerome Friedman.

The Elements of Statistical Learning: Data Mining, Inference, and Prediction.

Springer, 2009.



Justin Domke.

Generic methods for optimization-based modeling.

Journal of Machine Learning Research, 13:203–233, 2012.



Luca Franceschi, Michele Donini, Paolo Frasconi, and Massimiliano Pontil.

Forward and reverse gradient-based hyperparameter optimization.

In *Proceedings of the 34th International Conference on Machine Learning*, 2017.

Список литературы III



David H. Wolpert.

Stacked generalization.

Neural Networks, 5(2):241–259, 1992.



K. M. Ting and I. H. Witten.

Issues in stacked generalization.

Journal of Artificial Intelligence Research, 10:271–289, 1999.



R. Maclin and D. Opitz.

Popular ensemble methods: An empirical study.

Journal of Artificial Intelligence Research, 11:169–198, 1999.



Corinna Cortes, Javier Gonzalvo, Vitaly Kuznetsov, Mehryar Mohri, and Scott Yang.

Adanet: Adaptive structural learning of artificial neural networks.

In *Proceedings of the 34th International Conference on Machine Learning*, 2017.



Jonathan Lorraine, Paul Vicol, and David Duvenaud.

Optimizing millions of hyperparameters by implicit differentiation.

In *Proceedings of the 22nd International Conference on Artificial Intelligence and Statistics*, 2019.



Amirreza Shaban, Ching-An Cheng, Nolan Hatch, and Byron Boots.

Truncated back-propagation for bilevel optimization.

In *Proceedings of the 22nd International Conference on Artificial Intelligence and Statistics*, 2019.



Dougal Maclaurin, David Duvenaud, and Ryan P. Adams.

Gradient-based hyperparameter optimization through reversible learning.

In *Proceedings of the 32nd International Conference on Machine Learning*, 2015.

Список литературы IV



Fabian Pedregosa.

Hyperparameter optimization with approximate gradient.

In Proceedings of the 33rd International Conference on Machine Learning, 2016.



Atilim Gunes Baydin, Barak A. Pearlmutter, Alexey Andreyevich Radul, and Jeffrey Mark Siskind.

Automatic differentiation in machine learning: A survey.

Journal of Machine Learning Research, 18:1–43, 2018.



Jasper Snoek, Hugo Larochelle, and Ryan P. Adams.

Practical bayesian optimization of machine learning algorithms.

In Advances in Neural Information Processing Systems, 2012.



James Bergstra, Rémi Bardenet, Balázs Kégl, and Yoshua Bengio.

Algorithms for hyper-parameter optimization.

In Advances in Neural Information Processing Systems, 2011.



Anonymous.

Differentiable hyper-parameter optimization.

In International Conference on Learning Representations, 2022.